



UNIVERSIDADE FEDERAL DE SÃO CARLOS
DEPARTAMENTO DE COMPUTAÇÃO

BRENDA RAQUEL MAIA - 757891
BRUNA MATIAS DE LIMA - 820582
JOÃO MANOEL RIBEIRO MACHADO - 822447
JULIA PEDRO SILVA - 820869
LARISSA DIAS DA SILVA - 800204

**Deteccção e Classificação de Golpes Digitais e
Publicações Suspeitas em Redes Sociais**
RELATÓRIO 2

**SÃO CARLOS - SP
06/2026**

1. Introdução

A disseminação de golpes e mensagens fraudulentas em redes sociais tem se tornado um problema crescente, especialmente em plataformas de grande alcance como o Facebook, onde discursos persuasivos, ofertas enganosas e apelos emocionais são frequentemente utilizados para induzir usuários ao erro. Nesse contexto, técnicas de Processamento de Linguagem Natural (PLN) apresentam-se como uma abordagem eficaz para a identificação automática desse tipo de conteúdo, permitindo distinguir mensagens legítimas de mensagens fraudulentas com base em características textuais.

O presente relatório tem como objetivo dar continuidade ao trabalho iniciado no Seminário 1, detalhando a recapitulação da proposta apresentada, bem como as estratégias de pré-processamento e representação textual adotadas como etapa inicial do pipeline de classificação.

2. Recapitulação do Seminário 1

Definiu-se, como tarefa do presente trabalho, a **classificação binária de mensagens do Facebook em duas categorias: Ham (mensagens legítimas) e Spam (golpes/scams)**, a partir do dataset **BrScamsFacebook**.

O dataset é composto por **450 mensagens** extraídas de publicações e comentários do Facebook em língua portuguesa, originalmente anotadas em múltiplas categorias de golpe (problema multiclasse). Para os fins deste trabalho, tais categorias foram reagrupadas em duas classes: Ham e Spam, resultando em um conjunto de dados fortemente desbalanceado, com **375 mensagens classificadas como Spam (83,3%) e 75 mensagens classificadas como Ham (16,7%)**.

Como medidas de avaliação dos modelos a serem desenvolvidos, definiu-se a utilização de **acurácia, precisão, recall e F1-score**, com atenção específica ao desempenho na classe minoritária (Ham), dado o desbalanceamento observado. Complementarmente, será reportada a **matriz de confusão** de cada modelo, a fim

de possibilitar uma análise mais detalhada dos erros de classificação entre as duas categorias.

Em relação à proposta inicial apresentada no Seminário 1, a proposta original foi mantida integralmente.

3. Detalhamento das Estratégias

3.1. Pré-processamento e Representação Textual

Para o processamento da língua portuguesa, foram utilizadas as bibliotecas **NLTK**, responsável pela tokenização, pela remoção de stopwords e pela aplicação de stemming, e **spaCy**, por meio do modelo **pt_core_news_sm**, responsável pela lematização dos textos.

O pipeline de pré-processamento foi estruturado nas seguintes etapas:

1. **Limpeza textual:** remoção de URLs, menções (@usuário), emojis e caracteres especiais/pontuação, seguida de normalização por meio da conversão para caixa baixa e da remoção de acentuação gráfica.
2. **Tokenização e remoção de stopwords:** segmentação dos textos previamente limpos em tokens, com exclusão das palavras de baixo valor semântico (stopwords) da língua portuguesa.
3. **Redução morfológica:** aplicação de duas técnicas distintas, de forma comparativa: stemming, por meio do algoritmo RSLP, e lematização, por meio do modelo **pt_core_news_sm** do **spaCy**. A abordagem de stemming resultou em um vocabulário de **3.498 termos únicos**, ao passo que a lematização resultou em um vocabulário de **4.336 termos únicos**. Optou-se pela utilização da **lematização** como versão definitiva do texto pré-processado, tendo em vista dois fatores principais: (i) a preservação de palavras pertencentes ao léxico da língua portuguesa, favorecendo a interpretabilidade das características (*features*) extraídas nas etapas subsequentes de modelagem; e (ii) uma redução menos agressiva do vocabulário, considerada

mais adequada a um conjunto de dados composto por mensagens de curta extensão.

4. **Representação textual:** geração de duas representações vetoriais a partir do texto lematizado (por meio da biblioteca scikit-learn), **Bag-of-Words**, com o CountVectorizer, e **TF-IDF**, com o TfidfVectorizer, ambas limitadas a 3.000 features.

No que se refere às dificuldades encontradas ao longo do processo de pré-processamento, destacam-se:

- A **presença de textos curtos**, característica comum a comentários e publicações de redes sociais, contribui para o aumento da esparsidade das matrizes de representação geradas (Bag-of-Words e TF-IDF).
- O uso recorrente de **gírias, abreviações e desvios ortográficos**, elementos típicos da linguagem informal empregada em redes sociais, nem sempre adequadamente tratados pelas listas padrão de stopwords ou pelos modelos de stemming e lematização utilizados.
- A ocorrência de **erros de lematização em nomes próprios**, exemplificada pela palavra "Amanda" (nome próprio), que foi incorretamente lematizada como "amando" (forma flexionada do verbo "amar"), evidenciando uma limitação do modelo pt_core_news_sm no tratamento de nomes próprios em contextos informais.
- A **elevada esparsidade** observada nas matrizes de representação, decorrente da combinação entre o número reduzido de instâncias do dataset (450 mensagens) e um vocabulário relativamente extenso (4.336 termos após a lematização).
- O **desbalanceamento das classes** (83,3% Spam / 16,7% Ham), fator que deverá ser levado em consideração nas etapas subsequentes de modelagem e avaliação.

3.2. Estratégia 1: Abordagem Heurística (Regras)

Como primeira estratégia de classificação, foi implementado um classificador heurístico baseado em regras manuais, sem a utilização de técnicas de aprendizado

de máquina. Essa abordagem tem como objetivo identificar indícios textuais frequentemente associados a golpes digitais e mensagens fraudulentas, utilizando características observadas diretamente no conteúdo das mensagens.

A construção do classificador foi realizada a partir dos textos previamente processados na etapa descrita na Seção 3.1. Foram definidas regras baseadas em padrões recorrentes encontrados nas mensagens classificadas como Spam, sendo atribuída uma pontuação (score) para cada evidência identificada. Ao final da análise de cada mensagem, a soma das pontuações determina sua classificação como Ham ou Spam.

As heurísticas implementadas contemplam os seguintes aspectos:

- Presença de URLs ou links suspeitos, frequentemente utilizados para redirecionar usuários para páginas fraudulentas ou de coleta de dados;
- Presença de valores monetários ou referências financeiras, identificadas por meio de expressões regulares capazes de detectar padrões como "R\$", quantias numéricas e menções a pagamentos;
- Uso excessivo de letras maiúsculas, característica frequentemente associada a tentativas de chamar a atenção do usuário ou transmitir senso de urgência;
- Ocorrência de palavras-gatilho relacionadas a golpes, promoções enganosas, falsas oportunidades financeiras, relacionamentos fraudulentos e outros conteúdos suspeitos. Para essa finalidade, foi construído um léxico contendo termos como pix, prêmio, ganhador, grátis, promoção, oferta, sorteio, cartão, crédito, investimento, renda, amor, namorada, mentora, espiritual, emagrecimento, trabalho online, cassino, hacking e cura, entre outros.

A decisão final do classificador foi realizada por meio de um limiar de pontuação previamente definido. Após testes experimentais, adotou-se como critério a classificação de uma mensagem como Spam quando o score fosse maior ou igual a 2; caso contrário, a mensagem era classificada como Ham. Esse ajuste permitiu aumentar a quantidade de mensagens fraudulentas corretamente identificadas em relação à configuração inicial do modelo.

A avaliação da abordagem heurística foi realizada utilizando as métricas de Precisão, Recall, F1-Score e matriz de confusão. O modelo obteve precisão de 0,88,

recall de 0,29 e F1-Score de 0,43 para a classe Spam, além de acurácia geral de 37%. A matriz de confusão mostrou que 107 mensagens Spam e 61 mensagens Ham foram classificadas corretamente, enquanto ocorreram 268 falsos negativos e 14 falsos positivos. Esses resultados indicam que, embora o conjunto de regras seja eficaz para identificar mensagens que apresentam padrões explícitos de fraude, uma parcela significativa dos golpes não contém os indícios previstos pelas heurísticas implementadas.

A principal vantagem dessa abordagem é a sua simplicidade, interpretabilidade e baixo custo computacional, permitindo compreender diretamente quais características motivaram cada decisão de classificação. Além disso, trata-se de um modelo de fácil implementação e manutenção, podendo ser adaptado pela inclusão de novas regras ou palavras-gatilho sempre que novos padrões de golpes forem identificados.

Algumas limitações foram observadas. Por depender de regras fixas e de um conjunto previamente definido de palavras-gatilho, o modelo apresenta dificuldades para identificar variações linguísticas, sinônimos, erros ortográficos e novas estratégias de fraude que não estejam explicitamente contempladas nas heurísticas. Também foram observados falsos negativos em mensagens fraudulentas cujo conteúdo dependia mais do contexto semântico do que da ocorrência de palavras específicas, bem como falsos positivos em mensagens legítimas que continham termos presentes no léxico. Esses resultados evidenciam que, embora a abordagem heurística seja útil como linha de base (baseline) e apresente elevada interpretabilidade, sua capacidade de generalização é limitada quando comparada a modelos baseados em aprendizado de máquina.

3.3. Estratégia 2: Naive Bayes e Regressão Logística

Como segunda estratégia de classificação, foram implementados dois modelos clássicos de aprendizado de máquina supervisionado: o Naive Bayes, em sua variante Multinomial, e a Regressão Logística. Diferentemente da abordagem heurística descrita na Seção 3.2, que se baseia em regras manuais estáticas, esses algoritmos têm como objetivo aprender, a partir dos dados de treino, os padrões

probabilísticos e os pesos associados a cada termo do vocabulário gerado na etapa de pré-processamento.

Os modelos foram treinados a partir das representações vetoriais Bag-of-Words e TF-IDF geradas na Seção 3.1, de forma a permitir a comparação do desempenho de cada algoritmo sob as duas formas de representação textual. Para a validação dos modelos, adotou-se a validação cruzada estratificada (Stratified K-Fold) com cinco partições ($k=5$), garantindo que a proporção original de desbalanceamento entre as classes (aproximadamente 83% Spam e 17% Ham) fosse mantida em todas as dobras de treino e teste, dada a reduzida dimensão do dataset (450 instâncias).

Para o tratamento do desbalanceamento das classes, foram testadas versões balanceadas de ambos os algoritmos. Na Regressão Logística, o balanceamento foi realizado por meio do hiperparâmetro `class_weight='balanced'`, disponível na biblioteca `scikit-learn`, que atribui maior peso aos erros cometidos na classe minoritária (Ham) durante o treinamento. No Naive Bayes, como esse hiperparâmetro não está disponível, o balanceamento foi implementado por meio do ajuste manual do parâmetro `class_prior`, fixando uma distribuição uniforme (0,5 para cada classe), de modo a contrapor a probabilidade a priori naturalmente enviesada para a classe Spam que o modelo aprenderia a partir da distribuição real dos dados.

Adicionalmente, foi realizada uma busca de hiperparâmetros por meio da técnica de `GridSearchCV`, otimizando a métrica F1-Score macro, considerada mais adequada do que a acurácia dado o desbalanceamento das classes. Para o Naive Bayes, testou-se o parâmetro de suavização de Laplace (α), nos valores 0,1, 0,5, 1,0 e 2,0. Para a Regressão Logística, testou-se o parâmetro de regularização inversa (C), nos valores 0,01, 0,1, 1,0 e 10,0. Ao todo, foram avaliadas oito configurações de modelo, combinando os dois algoritmos, as duas representações vetoriais (BoW e TF-IDF) e as duas estratégias de balanceamento (padrão e balanceado).

Os resultados obtidos evidenciaram a importância tanto do ajuste de hiperparâmetros quanto do tratamento do desbalanceamento. Nas configurações iniciais, sem a busca de hiperparâmetros, os modelos de Naive Bayes com TF-IDF e Regressão Logística padrão com TF-IDF apresentaram um viés severo para a

classe majoritária, classificando praticamente todas as mensagens como Spam. Com a busca do parâmetro alpha, o valor ótimo encontrado para a maior parte das configurações de Naive Bayes foi 0,1, o que, isoladamente, já elevou de forma expressiva o recall da classe Ham. O balanceamento via `class_prior` teve efeito adicional relevante principalmente na representação TF-IDF, no qual o recall da classe Ham praticamente dobrou em relação à versão sem balanceamento.

O melhor resultado geral foi obtido pela Regressão Logística com representação TF-IDF e balanceamento de classes, utilizando o hiperparâmetro $C=0,1$, que alcançou F1-Score macro de 0,66, com precisão de 0,52 e recall de 0,35 para a classe Ham. Esse resultado superou a configuração equivalente com Bag-of-Words, que apresentou F1-Score macro de 0,65, ainda que com maior recall (0,55) e menor precisão (0,38) para a classe Ham. Observou-se, de forma consistente entre os modelos avaliados, um evidente trade-off entre precisão e recall na classe minoritária: modelos sem balanceamento tendem a apresentar maior precisão às custas de um recall muito baixo, enquanto modelos balanceados aumentam o recall ao custo de um número maior de falsos positivos.

Dentre as principais dificuldades encontradas nesta etapa, destaca-se o risco de overfitting decorrente da combinação entre um vocabulário relativamente extenso (3.000 features) e um número reduzido de instâncias de treino, especialmente na classe minoritária (apenas 75 exemplos de Ham), o que limita a capacidade de generalização dos modelos. Também foi identificada a dificuldade inerente ao ajuste do limiar de decisão (threshold): embora os hiperparâmetros de balanceamento tenham sido explorados, o limiar padrão de 0,5 utilizado pelos classificadores pode não ser o mais adequado para um problema com desbalanceamento tão acentuado, representando uma possível direção de aprimoramento para trabalhos futuros. Por fim, observou-se que a escolha da representação vetorial (BoW ou TF-IDF) interage de forma não trivial com o balanceamento aplicado, sendo necessário avaliar as combinações de forma conjunta, e não isoladamente, para identificar a configuração de melhor desempenho.

3.4. Estratégia 3: SVM e Árvores de Decisão / Random Forest

Como terceira estratégia de classificação, foi explorado o uso de algoritmos não lineares e baseados em conjuntos (ensembles): as Máquinas de Vetores de Suporte (Support Vector Machines, SVM), as Árvores de Decisão (Decision Trees) e as Florestas Aleatórias (Random Forests). O objetivo desta etapa consistiu em avaliar a capacidade desses classificadores de mapear fronteiras de decisão mais complexas no espaço vetorial, contrapondo-se às premissas de linearidade e independência de atributos das abordagens anteriores.

A metodologia de treinamento e validação seguiu o mesmo protocolo estabelecido na seção anterior. Utilizou-se a validação cruzada estratificada com cinco partições (k=5) aplicada sobre as matrizes Bag-of-Words (BoW) e TF-IDF. A otimização dos modelos foi conduzida via GridSearchCV, maximizando a métrica F1-Score macro.

Para o tratamento do desbalanceamento, aplicou-se o hiperparâmetro `class_weight='balanced'`. Esse ajuste penaliza os erros cometidos na classe minoritária de forma inversamente proporcional à sua frequência no conjunto de dados.

O espaço de busca de hiperparâmetros foi definido da seguinte forma:

- SVM: Explorou-se o parâmetro de regularização C nos valores 0.1, 1.0 e 10.0, avaliando-se os kernels linear e RBF (Radial Basis Function).
- Árvore de Decisão (DecisionTreeClassifier): Avaliou-se a profundidade da árvore (`max_depth`) nos valores None, 10 e 20, e o número mínimo de amostras para divisão de um nó (`min_samples_split`) entre 2, 5 e 10.
- Random Forest (RandomForestClassifier): Testou-se o número de estimadores (`n_estimators`) em 50, 100 e 200, combinado aos mesmos limites de `max_depth` aplicados à árvore simples.

Ao todo, foram geradas e avaliadas 12 configurações distintas de modelos, cujas previsões obtidas por validação cruzada e métricas consolidadas foram exportadas em um arquivo CSV para viabilizar a unificação e síntese comparativa do projeto.

Os resultados experimentais revelaram comportamentos distintos entre as arquiteturas. O modelo SVM mostrou-se altamente sensível ao parâmetro de regularização C. Em suas configurações padrão e com valores baixos de C, o

classificador exibiu forte tendência de colapso para a classe majoritária (Spam). Contudo, a combinação do kernel linear com a ativação do peso balanceado (`class_weight='balanced'`) propiciou um aumento no Recall da classe Ham. Já em relação à representação textual, o SVM performou significativamente melhor quando aplicado à normalização de frequências do TF-IDF, uma vez que a penalização de termos frequentes favoreceu a convergência algorítmica.

Por outro lado, as abordagens baseadas em árvores enfrentaram dificuldades induzidas pela natureza dos dados. A Árvore de Decisão apresentou uma forte tendência ao overfitting devido à alta dimensionalidade do vocabulário frente ao número reduzido de instâncias, resultando em alta variância nas partições de teste. O algoritmo de Random Forest diminuiu parte dessa limitação por meio da amostragem aleatória de atributos e do ajuste no número de estimadores (`n_estimators`), controlando de forma mais eficiente a variância geral.

4. Avaliação Quantitativa, Avaliação Qualitativa e Concordância

4.1 Avaliação quantitativa

A avaliação quantitativa foi realizada de maneira consolidada a partir das predições produzidas pelas três estratégias investigadas: abordagem heurística, modelos supervisionados probabilísticos e lineares (Naive Bayes e Regressão Logística) e modelos baseados em margem ou árvores (SVM, Árvore de Decisão e Random Forest). Para garantir uma comparação uniforme, todas as métricas foram recalculadas diretamente a partir dos rótulos reais e das predições obtidas por validação cruzada estratificada com cinco partições.

Devido ao desbalanceamento do conjunto binário, composto por 375 mensagens Spam e 75 mensagens Ham, o F1-Score macro foi adotado como principal critério de comparação. Essa métrica calcula o F1 de cada classe separadamente e atribui o mesmo peso às duas classes. Também foram reportadas a Precisão macro, a Revocação macro e a Acurácia (como medida complementar).

Tabela de comparação entre modelos:

Família	Configuração	Precisão macro	Recall macro	F1 macro	Acurácia	Recall Ham	Recall Spam
Regressão Logística	LogReg_TFIDF_Balanceado	0.699	0.641	0.661	0.838	0.347	0.936
Árvore de Decisão	ArvoreDecisao_TFIDF_Balanceado	0.653	0.655	0.654	0.807	0.427	0.883
SVM	SVM_BoW_Balanceado	0.624	0.672	0.636	0.756	0.547	0.797
Random Forest	RandomForest_BoW_Balanceado	0.668	0.613	0.63	0.827	0.293	0.933
Naive Bayes	NaiveBayes_TFIDF_Balanceado	0.597	0.633	0.605	0.736	0.48	0.787
Baseline	Baseline_Sempre_Spam	0.417	0.5	0.455	0.833	0.0	1.0
Heurística	Heuristica	0.535	0.549	0.367	0.373	0.813	0.285

Gráfico de comparação F1-Score:






Gráfico de comparação Recall:




O melhor resultado geral foi obtido pela Regressão Logística com representação TF-IDF e pesos de classe balanceados, alcançando F1 macro de 0,661. O modelo classificou corretamente 351 das 375 mensagens Spam, correspondendo ao recall de 0,936 para essa classe. Para Ham, obteve recall de 0,347, indicando que suas predições Ham foram relativamente confiáveis, embora parte considerável das mensagens legítimas ainda tenha sido classificada como Spam.




A Árvore de Decisão balanceada apresentou desempenho muito próximo, com F1 macro de 0,654 e comportamento mais equilibrado entre as classes: recall de 0,427 para Ham e de 0,883 para Spam. A SVM balanceada obteve a maior Revocação


macro entre as estratégias, com 0,672, e recall de 0,547 para Ham, mas apresentou mais mensagens Spam incorretamente classificadas como Ham, reduzindo sua acurácia para 0,756.




O Random Forest e o Naive Bayes apresentaram resultados intermediários. O Random Forest preservou recall elevado para Spam (0,933), mas identificou apenas 22 das mensagens Ham. O Naive Bayes balanceado aumentou o recall de Ham para 0,480, porém apresentou menor precisão para essa classe.



A comparação com a baseline evidencia por que a acurácia não deve ser utilizada isoladamente. A estratégia que classifica todas as mensagens como Spam alcança 83,3% de acurácia, valor próximo ao do melhor modelo, mas possui recall igual a 0 para Ham e F1 macro de apenas 0,455. Portanto, seu desempenho aparente é consequência direta da distribuição das classes e não de uma capacidade real de distinção.



A abordagem heurística apresentou F1 macro de 0,367. Seu recall para Spam foi de apenas 0,285, pois 268 das 375 mensagens fraudulentas não ativaram regras suficientes para ultrapassar o limiar. O resultado confirma que as regras funcionam em mensagens com indícios explícitos, como URLs, valores monetários e palavras-gatilho, mas possuem baixa cobertura diante de variações linguísticas e conteúdos que dependem de contexto.



4.2 Avaliação qualitativa e concordância entre avaliadores

Para a avaliação qualitativa, foi selecionada aleatoriamente uma amostra estratificada de 40 mensagens, contendo 20 mensagens Ham e 20 mensagens Spam. Escolhemos fazer uma amostra balanceada para garantir quantidade suficiente de exemplos das duas classes para a análise de erros. Essa amostra não foi utilizada para estimar a distribuição real do dataset.

As mensagens foram distribuídas aos cinco integrantes do grupo. Cada avaliador recebeu apenas o identificador e o texto da mensagem, sem acesso ao rótulo do dataset, às predições dos modelos ou às respostas dos demais integrantes. Para cada mensagem, foi solicitada uma classificação manual em Ham ou Spam, um nível de confiança de 1 a 5 e uma justificativa curta (opcional). Após a conclusão independente das avaliações, as respostas foram consolidadas e a concordância global foi calculada pelo índice Fleiss' Kappa, adequado à comparação de mais de dois avaliadores. Também foram calculados os valores de Cohen's Kappa para cada par de integrantes.

- Fleiss' Kappa: 0.4687
- Concordância média entre pares: 74.50%
- Taxa de unanimidade: 45%

A seguir, podemos observar **tabelas com resultados da avaliação qualitativa**:

Matriz de Cohen Kappa entre pares de avaliadores:

	Brenda	Bruna	Joao	Julia	Larissa
Brenda	1.000	0.579	0.333	0.333	0.529
Bruna	0.579	1.000	0.406	0.592	0.588
Joao	0.333	0.406	1.000	0.510	0.515
Julia	0.333	0.592	0.510	1.000	0.362
Larissa	0.529	0.588	0.515	0.362	1.000

Tabela de comparação entre avaliadores:

Avaliador	Precisao_Macro	Recall_Macro	F1_Macro	Acuracia
Brenda	0.833	0.750	0.733	0.750
Bruna	0.803	0.800	0.799	0.800
Joao	0.803	0.800	0.799	0.800
Julia	0.708	0.700	0.697	0.700
Larissa	0.885	0.850	0.847	0.850
Consenso	0.900	0.875	0.873	0.875

Casos com maior desacordo humano:

id_amostra	Rotulo_Real	votos_Ham	votos_Spam	consenso	grau_desacordo	predicao_melhor_modelo	consenso_diverge_dataset
Q02	Ham	3	2	Ham	0.4	Ham	FALSE
Q05	Spam	2	3	Spam	0.4	Spam	FALSE
Q09	Spam	3	2	Ham	0.4	Ham	TRUE
Q13	Ham	3	2	Ham	0.4	Ham	FALSE
Q27	Spam	2	3	Spam	0.4	Spam	FALSE
Q33	Ham	3	2	Ham	0.4	Spam	FALSE
Q40	Spam	3	2	Ham	0.4	Spam	TRUE
Q04	Spam	1	4	Spam	0.2	Spam	FALSE
Q06	Ham	4	1	Ham	0.2	Ham	FALSE
Q07	Ham	4	1	Ham	0.2	Spam	FALSE

Erros do melhor modelo em que o consenso humano coincide com o dataset:

id_amostra	Rotulo_Real	votos_Ham	votos_Spam	consenso	grau_desacordo	predicao_melhor_modelo	consenso_diverge_dataset
Q03	Ham	5	0	Ham	0.0	Spam	FALSE
Q07	Ham	4	1	Ham	0.2	Spam	FALSE
Q10	Ham	4	1	Ham	0.2	Spam	FALSE
Q12	Ham	4	1	Ham	0.2	Spam	FALSE
Q14	Ham	4	1	Ham	0.2	Spam	FALSE
Q15	Ham	5	0	Ham	0.0	Spam	FALSE
Q22	Ham	5	0	Ham	0.0	Spam	FALSE
Q32	Ham	5	0	Ham	0.0	Spam	FALSE
Q33	Ham	3	2	Ham	0.4	Spam	FALSE
Q38	Ham	5	0	Ham	0.0	Spam	FALSE

Casos em que o consenso humano diverge do rótulo do dataset:

id_amostra	Rotulo_Real	votos_Ham	votos_Spam	consenso	grau_desacordo	predicao_melhor_modelo	consenso_diverge_dataset
Q01	Spam	5	0	Ham	0.0	Spam	TRUE
Q09	Spam	3	2	Ham	0.4	Ham	TRUE
Q30	Spam	5	0	Ham	0.0	Spam	TRUE
Q31	Spam	4	1	Ham	0.2	Ham	TRUE
Q40	Spam	3	2	Ham	0.4	Spam	TRUE

Observamos que, de forma geral, a avaliação manual de mensagens demonstrou-se coerente ao apresentar classificações corretas na maioria dos casos. Obtivemos uma taxa de acertos relativamente boa, nos aproximando, inclusive, de avaliações feitas por alguns modelos.

A avaliação qualitativa também indicou um padrão relevante, que foi comum nas avaliações de todos os integrantes do grupo. Algumas mensagens Spam pertencentes à categoria de lojas virtuais falsas são extremamente curtas e genéricas, semelhantes a avaliações comuns de produtos, como “Queria sabores diferentes, mas não são”. Outras também faltam contexto para que seja realizada uma avaliação mais justa. Sem informações externas, o anúncio ou o vendedor, esses exemplos são linguisticamente difíceis de distinguir de mensagens legítimas.

5. Considerações Finais

O projeto permitiu comparar abordagens de diferentes níveis de complexidade para a classificação de mensagens do Facebook em Ham e Spam. A experiência mostrou que o pré-processamento e a representação textual têm influência direta no desempenho dos classificadores, principalmente em um conjunto pequeno, composto por textos curtos e informais.

Entre os modelos investigados, a Regressão Logística com TF-IDF e balanceamento de classes apresentou o melhor F1-Score macro. Esse resultado reforça que modelos lineares regularizados são adequados para dados textuais de alta dimensionalidade, especialmente quando o número de exemplos é limitado. Entretanto, nenhum modelo apresentou desempenho 100% satisfatório em todos os critérios.

A abordagem heurística foi importante como baseline interpretável. As decisões desse modelo podem ser explicadas diretamente pela ocorrência de links, valores monetários, letras maiúsculas e palavras-gatilho. Em contrapartida, o baixo recall para Spam demonstrou que regras fixas não generalizam bem para golpes implícitos, diferentes padrões linguísticos, erros ortográficos e mensagens cujo caráter fraudulento depende de contexto externo ao texto.

Como limitações que tivemos no desenvolvimento do projeto, observamos: o tamanho reduzido do dataset, o desbalanceamento resultante da conversão multiclasse para binária, a presença de mensagens muito curtas e a possível existência de exemplos ambíguos ou rótulos dependentes de contexto (que não era disponível).

Em uma aplicação real, seria ainda relevante combinar o texto com metadados, características de URLs, imagens, informações do perfil e contexto da publicação, pois vários exemplos não podem ser corretamente interpretados apenas pelo conteúdo textual.

De forma geral, o projeto evidenciou que a detecção de golpes em redes sociais não depende apenas da escolha do algoritmo. A qualidade dos rótulos, a representatividade dos dados, o tratamento do desbalanceamento e a análise qualitativa dos erros são componentes essenciais para produzir conclusões confiáveis.